

Profilage transcriptomique unicellulaire des PBMC humains

Contrôle qualité, annotation immunitaire, hétérogénéité lymphoïde,
trajectoire monocyttaire et scores de signatures

Rapport scientifique - jeu de données PBMC 3k

Analyse réalisée sous R / Seurat, avec scDbfFinder, Slingshot et AUCell

Version auditée - septembre 2026

Note de validation scientifique. L'audit final des marqueurs a montré que plusieurs étiquettes cellulaires utilisées lors d'une étape préliminaire ne correspondaient pas aux marqueurs observés. Le présent rapport utilise donc une annotation corrigée fondée sur les marqueurs différentiels et canoniques. Les analyses qui dépendaient directement de l'annotation préliminaire sont explicitement signalées comme exploratoires et ne sont pas utilisées pour tirer des conclusions biologiques finales.

Résumé

La transcriptomique unicellulaire permet de décomposer un échantillon biologique complexe en populations et états cellulaires définis par leurs profils d'expression. Dans cette étude, nous avons réanalysé le jeu de données public PBMC 3k de 10x Genomics, composé de 2 700 cellules mononucléées du sang périphérique et de 13 714 gènes. L'objectif était de construire un pipeline complet, reproductible et biologiquement interprétable allant du contrôle qualité à l'identification des populations immunitaires, puis d'explorer des structures plus fines par sous-clustering, pseudotemps et scores de signatures. Après filtrage des cellules selon le nombre de gènes détectés et la proportion de transcrits mitochondriaux, 2 689 cellules ont été conservées. scDbtFinder a identifié 114 doublets prédits (4,24 % des cellules post-QC), conduisant à un jeu final de 2 575 singlets. La normalisation par SCTransform v2, suivie d'une PCA, d'un graphe de voisinage et d'un clustering de Louvain, a révélé dix clusters. L'audit des marqueurs différentiels a permis une annotation révisée et cohérente avec la biologie des PBMC : lymphocytes CD4 naïfs et mémoire, monocytes CD14+ et FCGR3A+, lymphocytes B, deux états CD8 distincts (GZMK+ et cytotoxique), cellules NK, cellules dendritiques CD1C+/FCER1A+ et plaquettes. Les signatures AUCell myéloïde et B se localisaient respectivement dans les régions attendues de l'UMAP, fournissant une validation orthogonale de cette annotation. Une analyse Slingshot limitée au compartiment monocyttaire a mis en évidence un continuum transcriptionnel partant d'un état enrichi en CD14 vers des états plus FCGR3A+, interprété comme pseudotemps et non comme preuve de filiation. Enfin, l'expression de couples ligand-récepteur a été explorée de manière descriptive. L'ensemble montre qu'une analyse scRNA-seq robuste dépend autant du contrôle technique que de l'audit biologique des annotations et de la distinction entre analyses descriptives, inférentielles et exploratoires.

Mots-clés : scRNA-seq ; PBMC ; Seurat ; SCTransform ; doublets ; annotation cellulaire ; UMAP ; Slingshot ; pseudotemps ; AUCell.

Points principaux

- 2 575 singlets retenus à partir de 2 700 cellules initiales, après contrôle qualité et détection des doublets.
- Dix clusters transcriptomiques identifiés avec une structure conforme aux principales populations immunitaires attendues dans des PBMC.
- L'audit des marqueurs a corrigé l'annotation préliminaire et révélé deux états CD8 distincts, dont un compartiment GZMK+ et un compartiment cytotoxique.
- Le pseudotemps Slingshot est limité aux monocytes et décrit un continuum transcriptionnel sans être interprété comme une preuve de filiation.
- Les analyses dépendantes des étiquettes préliminaires sont séparées des résultats finaux afin de préserver la validité biologique de l'interprétation.

Abréviations

Abréviation	Définition
PBMC	Peripheral Blood Mononuclear Cells
scRNA-seq	single-cell RNA sequencing
UMI	Unique Molecular Identifier
QC	Quality Control / contrôle qualité
PCA	Principal Component Analysis
UMAP	Uniform Manifold Approximation and Projection
SCT	assay issu de SCTransform
DE	Differential Expression / expression différentielle
AUC	Area Under the Curve

1. Introduction

La transcriptomique unicellulaire a profondément modifié l'étude des tissus hétérogènes en permettant de mesurer, cellule par cellule, l'abondance de milliers de transcrits. Contrairement aux approches bulk, qui produisent un signal moyen, le scRNA-seq rend accessibles la composition cellulaire, les états d'activation, les transitions transcriptionnelles et les populations rares. Les technologies microfluidiques à gouttelettes ont rendu possible l'analyse de plusieurs milliers à plusieurs dizaines de milliers de cellules dans une même expérience, au prix d'une forte sparsité des matrices d'expression et de biais techniques spécifiques [1].

Les PBMC constituent un modèle de référence pour l'apprentissage et la validation des workflows scRNA-seq. Elles regroupent majoritairement des lymphocytes T, B et NK, des monocytes, ainsi qu'une fraction plus faible de cellules dendritiques et de plaquettes. Le jeu de données PBMC 3k, mis à disposition par 10x Genomics et repris dans les tutoriels Seurat, contient 2 700 cellules détectées et a été séquencé sur Illumina NextSeq 500 [1,10]. Sa composition relativement simple en fait un benchmark utile pour évaluer les décisions méthodologiques de contrôle qualité, normalisation, réduction de dimension, clustering et annotation.

La principale difficulté d'un pipeline scRNA-seq n'est pas de produire un UMAP, mais de distinguer ce qui relève d'un effet technique de ce qui reflète une structure biologique. Les différences de profondeur de séquençage, les transcrits mitochondriaux, les doublets, le cycle cellulaire et la sparsité peuvent modifier l'organisation des cellules dans l'espace réduit. SCTransform modélise les comptes UMI par régression binomiale négative régularisée et vise à stabiliser la variance tout en réduisant l'influence de la profondeur de séquençage [2]. La détection des doublets est également indispensable, car des gouttelettes contenant deux cellules peuvent générer des profils hybrides et créer artificiellement des clusters ou des marqueurs [3].

La présente étude poursuit deux objectifs. Le premier est méthodologique : établir un pipeline lisible, reproductible et justifié, dans lequel chaque transformation répond à une question explicite. Le second est biologique : reconstruire la composition immunitaire des PBMC 3k, caractériser les marqueurs de chaque cluster, tester la cohérence de l'annotation par des signatures indépendantes et explorer un continuum monocyttaire par pseudotemps. Une attention particulière est portée à la validation des étiquettes cellulaires, car une annotation incorrecte se propage directement aux analyses en aval.

2. Matériels et méthodes

2.1. Jeu de données et environnement analytique

Le jeu de données analysé est PBMC 3k, un jeu public de PBMC humains sains distribué par 10x Genomics et accessible via SeuratData. L'objet chargé comportait 13 714 gènes et 2 700 cellules. L'analyse a été réalisée sous R 4.6.0 avec Seurat, SeuratData, scDbfFinder, SingleCellExperiment, Slingshot, AUCell, ggplot2, dplyr et patchwork. Un seed fixé à 42 a été utilisé pour les étapes stochastiques, et les informations de session ont été exportées à la fin du workflow afin de renforcer la reproductibilité.

2.2. Contrôle qualité

Pour chaque cellule, quatre indicateurs ont été examinés : le nombre de gènes détectés (nFeature_RNA), le nombre total d'UMI (nCount_RNA), la proportion de transcrits mitochondriaux et la proportion de transcrits ribosomiques. Les distributions ont été visualisées avant filtrage, puis les relations nCount_RNA–nFeature_RNA et nCount_RNA–percent.mt ont été examinées afin de repérer les cellules présentant un profil atypique. Les cellules ont été conservées lorsqu'elles exprimaient plus de 200 et moins de 2 500 gènes, avec moins de 10 % de transcrits mitochondriaux. Ce seuil est adapté ici à la distribution observée et ne doit pas être considéré comme une constante universelle.

2.3. Détection des doublets

Les doublets ont été identifiés avec scDbfFinder, après conversion temporaire de l'objet Seurat en SingleCellExperiment. scDbfFinder attribue à chaque cellule un score continu et une classe singlet/doublet à partir de profils simulés et observés [3]. Un UMAP temporaire, construit uniquement à des fins de diagnostic, a permis de visualiser la distribution des scores. Seules les cellules classées singlet ont été retenues pour l'analyse principale.

2.4. Évaluation du cycle cellulaire

Les scores S et G2/M ont été calculés à partir des listes de gènes de cycle fournies par Seurat. Une PCA dédiée aux gènes de cycle a été utilisée comme diagnostic afin d'évaluer si la progression du cycle constituait une source dominante de séparation entre cellules. Cette PCA n'a pas été utilisée pour le clustering final. Les scores de cycle n'ont pas été régressés de manière systématique, afin d'éviter d'éliminer une composante potentiellement biologique en l'absence d'une structure clairement dominée par le cycle.

2.5. Normalisation, réduction de dimension et clustering

Les comptes RNA ont été normalisés par SCTransform v2, avec régression de la proportion mitochondriale. SCTransform repose sur une régression binomiale négative régularisée et fournit des résidus stabilisés adaptés aux analyses en aval [2]. Une PCA de 50 composantes a ensuite été calculée. L'Elbow plot a montré une décroissance rapide de l'information portée par les premières composantes puis un aplatissement progressif ; les 20 premières composantes ont été retenues pour la construction du graphe de voisinage, le clustering et l'UMAP.

Le graphe de voisinage a été construit dans l'espace des 20 premières composantes principales. Le clustering a été réalisé avec l'algorithme de Louvain à une résolution de 0,5, puis les cellules ont été projetées en deux dimensions par UMAP. UMAP est ici un outil de visualisation de la structure locale et globale approximative ; il ne constitue ni une métrique de distance biologique absolue ni l'étape qui crée les clusters [4].

2.6. Identification des marqueurs et annotation

Les marqueurs positifs de chaque cluster ont été identifiés par test de Wilcoxon, en exigeant une détection dans au moins 25 % des cellules d'un des groupes comparés et un log2 fold-change minimal de 0,25. L'annotation n'a pas été déduite du numéro des clusters. Elle a été déterminée par convergence entre les gènes les plus enrichis et un panel de marqueurs canoniques comprenant notamment CCR7/IL7R pour les lymphocytes T CD4, CD14/S100A8/S100A9 pour les monocytes classiques, MS4A1/CD79A pour les lymphocytes B, NKG7/GNLY/PRF1 pour les cellules NK, FCGR3A/MS4A7/LST1 pour les monocytes non classiques, FCER1A/CD1C/CST3 pour les cellules dendritiques et PPBP/PF4/GP9 pour les plaquettes. Cette étape d'audit a conduit à corriger plusieurs étiquettes de la table d'annotation préliminaire.

2.7. Analyses ciblées

Deux analyses ciblées ont été retenues pour l'interprétation finale. Premièrement, le compartiment monocyttaire CD14+/FCGR3A+ a été extrait, renormalisé et reclusté avant l'inférence de pseudotemps avec Slingshot. Le cluster de départ a été choisi de manière data-driven comme celui présentant l'expression moyenne de CD14 la plus élevée. Slingshot construit une trajectoire dans un espace réduit et attribue aux cellules une position relative le long de la lignée inférée [5]. Deuxièmement, AUCell a été utilisé pour calculer, cellule par cellule, l'enrichissement de deux signatures ciblées : une signature myéloïde et une signature B. AUCell repose sur le rang des gènes au sein de chaque cellule et mesure l'enrichissement d'un ensemble de gènes parmi les gènes les mieux classés [6].

L'expression moyenne de plusieurs couples ligand-récepteur candidats (CD40LG–CD40, CCL5–CCR5, TNF–TNFRSF1A, IL2–IL2RA) a également été explorée. Cette analyse est descriptive : la co-expression d'un ligand dans une population et de son récepteur dans une autre ne démontre ni proximité spatiale, ni contact, ni activation effective d'une voie de signalisation.

2.8. Audit de validité des analyses dépendantes de l'annotation

Une vérification croisée des marqueurs a montré que la table d'annotation préliminaire utilisée lors d'une première exécution du script était décalée pour plusieurs clusters. En conséquence, le sous-clustering initial intitulé « T/NK » avait inclus un cluster B et exclu des clusters CD8 authentiques. Ce résultat est conservé comme trace exploratoire mais n'est pas interprété biologiquement dans le présent rapport. De même, les figures de ligand-récepteur générées avec les anciennes étiquettes ont été remappées sur les identités corrigées avant interprétation.

2.9. Paramètres principaux du workflow

Étape	Paramètre	Valeur utilisée
QC	nFeature_RNA	> 200 et < 2 500
QC	percent.mt	< 10 %
Doublets	Méthode	scDblFinder
Normalisation	Méthode	SCTransform v2
Normalisation	Covariable régressée	percent.mt
PCA	Nombre calculé	50 composantes
Dimensions utilisées	PCA	PC1–PC20
Clustering	Algorithme	Louvain
Clustering	Résolution	0,5
Marqueurs	Test	Wilcoxon
Marqueurs	min.pct	0,25
Marqueurs	log2FC minimal	0,25
Monocytes	Dimensions	PC1–PC15
Monocytes	Résolution	0,4
Pseudotemps	Méthode	Slingshot, départ CD14-high

3. Résultats

3.1. Contrôle qualité : une matrice globalement homogène avec peu de cellules extrêmes

L'objet initial contenait 2 700 cellules et 13 714 gènes. Les distributions de nFeature_RNA, nCount_RNA et percent.mt étaient centrées sur des valeurs compatibles avec une bibliothèque PBMC peu complexe, avec une minorité de cellules présentant un nombre de gènes ou une fraction mitochondriale plus élevés. Le nombre d'UMI et le nombre de gènes détectés étaient fortement corrélés ($r \approx 0,95$), ce qui est attendu lorsque l'augmentation de la profondeur moléculaire permet de détecter davantage de gènes. À l'inverse, la corrélation entre nCount_RNA et percent.mt était faible et négative ($r \approx -0,13$), sans relation linéaire majeure.




Figure 1. Distributions des métriques de contrôle qualité avant filtrage. Les violons montrent le nombre de gènes détectés, le nombre total d'UMI, la proportion de transcrits mitochondriaux et la proportion de transcrits ribosomiques par cellule.




Figure 2. Relations entre profondeur moléculaire et complexité/transcrits mitochondriaux. La corrélation `nCount_RNA`–`nFeature_RNA` est forte ($\approx 0,95$), tandis que `nCount_RNA`–`percent.mt` est faiblement négative ($\approx -0,13$).

Après application des seuils `nFeature_RNA` > 200, `nFeature_RNA` < 2 500 et `percent.mt` < 10 %, 2 689 cellules ont été conservées. Le filtrage initial n'a donc éliminé que 11 cellules (0,41 %), ce qui indique que la majorité des cellules du jeu PBMC 3k satisfaisait déjà les critères de qualité retenus.

3.2. scDbtFinder élimine 114 profils potentiellement composites

scDbtFinder a classé 114 cellules comme doublets et 2 575 comme singlets, soit un taux de doublets prédits de 4,24 % parmi les cellules post-QC. Les cellules à score élevé se distribuaient principalement dans des régions périphériques ou de transition de l'UMAP diagnostique, ce qui est compatible avec l'idée que les doublets hétérotypiques combinent des programmes transcriptomiques provenant de deux populations. Toutes les analyses ultérieures ont été réalisées sur les 2 575 singlets, correspondant à 95,37 % des cellules initiales.




Figure 3. Détection des doublets par scDbtFinder. À gauche, classification singlet/doublet sur un UMAP diagnostique ; à droite, distribution spatiale du score continu de doublet.

3.3. Le cycle cellulaire ne domine pas l'organisation globale

Le scoring attribuait 1 144 cellules à la phase G1 (44,4 %), 1 049 à la phase S (40,7 %) et 382 à la phase G2/M (14,8 %). La PCA calculée uniquement à partir des gènes S/G2M montrait un chevauchement substantiel des phases, sans séparation nette capable d'expliquer à elle seule la structure globale du jeu de données. Le cycle a donc été conservé comme information biologique et n'a pas été régressé dans le modèle final.




Figure 4. PCA diagnostique calculée sur les gènes associés aux phases S et G2/M. Le chevauchement des groupes suggère que le cycle cellulaire n'est pas la principale source de structure du jeu de données.

3.4. Vingt composantes principales capturent l'essentiel de la structure utile au clustering

Après SCTransform, la décroissance de la variance portée par les composantes principales était très marquée pour les premières dimensions, puis devenait progressivement plus faible. L'Elbow plot ne montre pas une rupture unique et absolue, mais l'aplatissement devient net autour des premières dizaines de composantes. Le choix de 20 PCs fournit ainsi un compromis conservateur entre conservation de l'hétérogénéité biologique et limitation du bruit de dimensions de rang élevé.




Figure 5. Elbow plot des 50 premières composantes principales après SCTransform. Les 20 premières composantes ont été utilisées pour le graphe de voisinage, le clustering et l'UMAP.

3.5. Le clustering de Louvain met en évidence dix groupes transcriptomiques

Le clustering à résolution 0,5 a identifié dix clusters de tailles très différentes, allant de 13 à 540 cellules. L'UMAP met en évidence plusieurs ensembles bien séparés et d'autres reliés par des transitions plus

continues. Cette géométrie est compatible avec la coexistence de lignages immunitaires distincts et de sous-états proches au sein d'un même lignage. Le numéro d'un cluster n'a pas de signification biologique intrinsèque ; l'identité cellulaire a donc été déterminée uniquement après analyse des marqueurs.




Figure 6. UMAP des 2 575 singlets après SCTransform, PCA et clustering de Louvain. Dix clusters sont détectés (0 à 9).

3.6. L’audit des marqueurs conduit à une annotation corrigée

La combinaison des marqueurs différentiels et du DotPlot canonique a révélé une discordance entre plusieurs étiquettes préliminaires et les profils moléculaires réellement observés. Ce contrôle est central : sans lui, le cluster 3 aurait été appelé CD8 alors qu'il exprime fortement CD79A, MS4A1, TCL1A et VPREB3, et le cluster 9 serait resté « unassigned » malgré une signature plaquettaire extrêmement spécifique. L'annotation finale utilisée dans ce rapport est donc la suivante.




Figure 7. DotPlot des marqueurs canoniques par cluster. La taille des points représente la proportion de cellules exprimant le gène et la couleur son niveau moyen d'expression. Cette figure constitue le support principal de l'annotation manuelle.

Cluster	n	%	Marqueurs saillants	Annotation finale
---------	---	---	---------------------	-------------------

0	540	20,97	CCR7, LEF1, TCF7, MAL	CD4 T naïfs
1	534	20,74	AQP3, CD40LG, IL7R, LTB	CD4 T mémoire
2	479	18,60	S100A8, S100A9, S100A12, CD14	Monocytes CD14+
3	336	13,05	CD79A, MS4A1, TCL1A, VPREB3	Cellules B
4	213	8,27	GZMK, CD8A, CD8B, CCL5, IL7R	CD8 T GZMK+
5	147	5,71	GNLY, GZMB, PRF1, FGFBP2, NKG7	Cellules NK
6	144	5,59	FCGR3A, MS4A7, LST1, CDKN1C	Monocytes FCGR3A+
7	136	5,28	GZMH, CD8A/B, CCL5, NKG7, GZMB	CD8 T cytotoxiques
8	33	1,28	FCER1A, CD1C, CLEC10A, CST3	Cellules dendritiques CD1C+/FCER1A+
9	13	0,50	PPBP, PF4, GP9, ITGA2B, GNG11	Plaquettes

Tableau 1. Annotation finale des dix clusters fondée sur les marqueurs différentiels et canoniques. Les proportions sont calculées parmi les 2 575 singlets.

Cette réannotation explique pourquoi dix clusters ont été obtenus alors que le tutoriel PBMC3k est souvent présenté avec un nombre plus faible de catégories principales : les lymphocytes CD8 sont ici séparés en au moins deux états transcriptomiques. Le cluster 4 est enrichi en GZMK, CD8A/CD8B, CCL5 et IL7R, compatible avec un état CD8 GZMK+, tandis que le cluster 7 combine CD8A/CD8B avec GZMH, GZMB, PRF1, NKG7 et CCL5, compatible avec un programme plus cytotoxique. Cette distinction est biologiquement plus informative que de forcer les deux groupes dans une seule classe.




Figure 8. Composition cellulaire après correction de l'annotation. Les deux états CD8 sont conservés séparément afin de refléter l'hétérogénéité révélée par les marqueurs.

3.7. Validation orthogonale par AUCell

Deux signatures ciblées ont été évaluées sans utiliser les étiquettes cellulaires comme entrée du calcul : une signature myéloïde (LYZ, LST1, S100A8, S100A9, CTSS, FCGR3A) et une signature B (MS4A1, CD79A, CD37, CD79B, HLA-DRA). La signature myéloïde présente ses scores les plus élevés dans la région UMAP correspondant aux clusters monocytaires, tandis que la signature B est maximale dans le cluster 3. Cette concordance constitue une validation indépendante de l'annotation corrigée. Les signatures restent toutefois volontairement courtes ; elles doivent être interprétées comme des scores ciblés et non comme des régulons complets ou des programmes transcriptionnels exhaustifs.




Figure 9. Scores AUCell des signatures myéloïde et B projetés sur l'UMAP. La localisation des scores élevés concorde avec les clusters identifiés respectivement comme myéloïdes et B.

3.8. Un continuum transcriptionnel est détecté dans le compartiment monocyttaire

L'analyse de trajectoire a été limitée aux monocytes CD14+ et FCGR3A+, deux populations dont l'annotation était soutenue de manière non ambiguë par les marqueurs. Après reclustering spécifique du compartiment, le cluster présentant l'expression moyenne de CD14 la plus élevée a été choisi comme origine du pseudotemps. Slingshot a identifié une lignée principale dont le pseudotemps augmente de manière continue à travers l'UMAP monocyttaire. Cette organisation est compatible avec un continuum entre états monocytaires CD14-high et FCGR3A-enrichis, mais elle ne prouve pas que les cellules ont été observées au cours d'une différenciation réelle. Le pseudotemps ordonne des états transcriptionnels dans un échantillon transversal ; il ne constitue pas une mesure chronologique directe [5].




Figure 10. Pseudotemps Slingshot dans le compartiment monocytaire. Les cellules sont colorées selon leur position relative le long de la lignée inférée ; l'origine a été définie par le sous-cluster présentant l'expression moyenne de CD14 la plus élevée.

3.9. Expression de couples ligand-récepteur : signal descriptif, non preuve de communication

Après remappage des étiquettes sur l'annotation corrigée, l'expression moyenne de plusieurs gènes présente des patterns cohérents avec leur biologie attendue. CD40LG est principalement associé aux compartiments CD4, CD40 est plus marqué dans le cluster B et dans certaines populations myéloïdes, CCL5 est fortement exprimé dans les compartiments CD8 cytotoxiques/GZMK+ et NK, tandis que TNFRSF1A est davantage présent dans les monocytes. L'IL2RA reste globalement peu exprimé dans ce jeu de données. Ces observations permettent de formuler des hypothèses sur des axes d'interaction potentiels, mais une analyse de communication cellulaire nécessiterait un modèle dédié intégrant une base ligand-récepteur et, idéalement, des informations supplémentaires de contexte ou de validation.




Figure 11. Expression moyenne de gènes ligand-récepteur candidats après remappage des annotations. Les valeurs sont affichées sur une échelle $\log(1+x)$ uniquement pour faciliter la visualisation ; cette figure ne démontre pas une communication cellulaire effective.

3.10. Sous-clustering lymphoïde préliminaire : résultat technique à ne pas surinterpréter

Le sous-clustering initial intitulé « T/NK » a produit six sous-clusters et un panel de marqueurs incluant CCR7, IL7R, LTB, CD8A, GZMK, CCL5, NKG7, GNLY, PRF1, IL2RA, CTLA4 et FOXP3. Toutefois, l'audit ultérieur a montré que la sélection des cellules reposait sur une table d'annotation préliminaire incorrecte : un cluster B avait été inclus sous l'étiquette CD8, tandis que des clusters CD8 authentiques n'avaient pas été sélectionnés. La structure obtenue ne peut donc pas être utilisée pour conclure sur les sous-populations T/NK. La bonne pratique consiste à corriger la table d'annotation, reconstruire le sous-ensemble lymphoïde, puis répéter SCTransform, PCA, voisinage, clustering, UMAP et recherche de marqueurs. Ce point illustre qu'une étape de calcul techniquement correcte peut produire une interprétation biologique invalide si les étiquettes d'entrée sont erronées.

4. Discussion

4.1. La structure globale recapitule l'organisation attendue des PBMC

Après correction des annotations, l'organisation obtenue est très cohérente avec la composition attendue d'un échantillon PBMC : deux compartiments CD4, des lymphocytes B, des cellules NK, des monocytes classiques et FCGR3A+, des cellules dendritiques et une faible fraction plaquettaire. Cette architecture recoupe les populations identifiées dans le tutoriel PBMC3k de Seurat et dans la littérature fondatrice des plateformes 10x [1,10]. La séparation supplémentaire des cellules CD8 en un état GZMK+ et un état cytotoxique reflète une granularité supérieure du clustering plutôt qu'une contradiction avec le modèle de référence.

4.2. La qualité de l'annotation est plus importante que la stabilité des numéros de clusters

L'un des enseignements majeurs de cette analyse est que les numéros de clusters sont des identifiants algorithmiques et non des identités biologiques. Les clusters 0 et 1 ont par exemple été inversés lors d'une annotation préliminaire : le cluster 0 présente CCR7, LEF1 et TCF7, compatibles avec un état naïf, alors que le cluster 1 est enrichi en AQP3, CD40LG et IL7R, davantage compatible avec un état mémoire. Des erreurs plus importantes concernaient les clusters B, CD8, dendritiques et plaquettaires. La vérification systématique par plusieurs marqueurs est donc indispensable avant toute analyse en aval.

4.3. Le contrôle des doublets limite les artefacts de populations hybrides

Le taux de doublets prédits de 4,24 % est plausible pour un jeu de données de cette taille et rappelle qu'une fraction non négligeable des gouttelettes peut contenir plus d'une cellule. Leur retrait réduit le risque de créer des profils artificiellement intermédiaires et de surestimer l'expression conjointe de marqueurs appartenant à des lignages distincts. scDbtFinder a été développé spécifiquement pour ce type de problème et a montré de bonnes performances sur plusieurs jeux scRNA-seq [3].

4.4. SCTransform et la réduction de dimension fournissent une représentation robuste mais paramétrique

SCTransform est adapté aux données UMI car il modélise explicitement la relation moyenne-variance et la profondeur de séquençage [2]. Néanmoins, aucun choix de normalisation, de nombre de PCs ou de résolution n'est totalement neutre. La séparation de deux états CD8 illustre cette dépendance : avec une résolution différente ou un nombre de PCs différent, ces états pourraient fusionner ou se subdiviser. Le résultat final doit donc être jugé sur sa stabilité, sa cohérence avec les marqueurs et sa pertinence biologique plutôt que sur un nombre de clusters prédéfini.

4.5. Pseudotemps et communication cellulaire : distinguer structure descriptive et causalité

Le pseudotemps Slingshot ordonne les cellules selon une trajectoire compatible avec un continuum transcriptionnel ; il ne suit pas physiquement une cellule au cours du temps. L'interprétation causale d'une maturation CD14+ vers FCGR3A+ nécessiterait des données temporelles, un marquage de lignée ou des validations fonctionnelles. De même, l'expression conjointe de ligands et de récepteurs ne suffit pas à démontrer une interaction intercellulaire. Ces analyses sont utiles pour générer des hypothèses, mais leur niveau de preuve doit être distingué de celui de l'annotation fondée sur des marqueurs directement observés.

4.6. Limites

- Le jeu PBMC 3k correspond à un seul échantillon de référence ; les cellules individuelles ne constituent pas des réplicats biologiques indépendants. Les p-values de marqueurs décrivent donc une séparation au sein de ce jeu et ne doivent pas être extrapolées à une population humaine sans réplication inter-individuelle.
- Les seuils de QC sont adaptés à ce jeu et ne doivent pas être transposés mécaniquement à d'autres expériences, tissus ou technologies.
- Les clusters rares, notamment les cellules dendritiques (33 cellules) et les plaquettes (13 cellules), offrent des estimations moins stables que les grandes populations.
- L'annotation est fondée sur des marqueurs manuels. Une validation complémentaire par transfert de labels, atlas de référence ou annotation indépendante pourrait être ajoutée.
- Le sous-clustering T/NK doit être répété après correction de l'annotation de base ; il n'est donc pas retenu comme résultat biologique final dans cette version.
- Les signatures AUCell sont courtes et servent de validation ciblée ; elles ne représentent pas des régulateurs inférés ni des programmes exhaustifs.
- Les analyses ligand-récepteur sont descriptives et ne remplacent pas des approches spécialisées telles que CellChat, CellPhoneDB ou NicheNet.

5. Conclusion

Cette analyse du jeu PBMC 3k illustre un workflow scRNA-seq complet dans lequel la robustesse ne repose pas uniquement sur l'enchaînement de fonctions logicielles, mais sur des contrôles biologiques explicites à chaque étape. Le contrôle qualité et la détection des doublets ont permis de retenir 2 575 singlets de bonne qualité. SCTransform, la PCA et le clustering de Louvain ont révélé dix groupes transcriptomiques. L'audit des marqueurs a permis de corriger l'annotation et de reconstruire une architecture immunitaire cohérente, comprenant deux états CD8 distincts, des compartiments CD4, B, NK, monocytaires, dendritiques et plaquettaires. Les scores AUCell ont fourni une validation indépendante des identités myéloïdes et B, tandis que Slingshot a mis en évidence un continuum transcriptionnel monocytaire interprété avec prudence. Enfin, l'analyse a montré de manière concrète qu'une annotation non vérifiée peut invalider les analyses en aval, même lorsque leur exécution informatique est correcte. Cette distinction entre validité technique et validité biologique constitue l'un des principes essentiels d'une analyse single-cell de niveau recherche.

6. Reproductibilité et disponibilité

Le pipeline a été exécuté avec un seed fixé à 42. Les objets Seurat intermédiaires et finaux, les tableaux de marqueurs, les figures et les informations de session ont été sauvegardés au cours de l'analyse. Le jeu PBMC 3k est publiquement disponible via 10x Genomics et SeuratData. Le script complet n'est volontairement pas reproduit dans le corps du rapport ; les méthodes sont décrites au niveau nécessaire pour comprendre et reproduire la logique analytique.

7. Note d'audit : différence entre annotation préliminaire et annotation finale

Le tableau ci-dessous documente les corrections appliquées lors de la revue finale. Cette traçabilité est volontaire : dans un contexte de recherche, corriger une annotation à partir des données est préférable à conserver une étiquette héritée d'un exemple ou d'une exécution antérieure.

Cluster	Étiquette préliminaire	Étiquette finale	Argument principal
0	CD4+ T Memory	CD4 T naïfs	CCR7, LEF1, TCF7
1	CD4+ T Naive	CD4 T mémoire	AQP3, CD40LG, IL7R
2	CD14+ Monocytes	Monocytes CD14+	concordant
3	CD8+ T Cells	Cellules B	CD79A, MS4A1, TCL1A
4	B Cells	CD8 T GZMK+	CD8A/B, GZMK, CCL5
5	NK Cells	Cellules NK	GNLY, GZMB, PRF1
6	FCGR3A+ Monocytes	Monocytes FCGR3A+	concordant
7	Dendritic Cells	CD8 T cytotoxiques	CD3D, CD8A/B, GZMH, NKG7
8	Platelets	Cellules dendritiques	FCER1A, CD1C, CLEC10A
9	unassigned	Plaquettes	PPBP, PF4, GP9, ITGA2B

Tableau 2. Audit des étiquettes de clusters. Les analyses finales et la discussion utilisent exclusivement la colonne « Étiquette finale ».

8. Références

1. Zheng GX, Terry JM, Belgrader P, et al.. *Massively parallel digital transcriptional profiling of single cells*. Nature Communications. 2017; 8:14049. <https://doi.org/10.1038/ncomms14049>
2. Hafemeister C, Satija R.. *Normalization and variance stabilization of single-cell RNA-seq data using regularized negative binomial regression*. Genome Biology. 2019; 20:296. <https://doi.org/10.1186/s13059-019-1874-1>
3. Germain PL, Lun A, Garcia Meixide C, Macnair W, Robinson MD.. *Doublet identification in single-cell sequencing data using scDblFinder*. F1000Research. 2022; 10:979. <https://doi.org/10.12688/f1000research.73600.2>

4. McInnes L, Healy J, Melville J.. *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. arXiv. 2018; arXiv:1802.03426. <https://arxiv.org/abs/1802.03426>
5. Street K, Risso D, Fletcher RB, et al.. *Slingshot: cell lineage and pseudotime inference for single-cell transcriptomics*. BMC Genomics. 2018; 19:477. <https://doi.org/10.1186/s12864-018-4772-0>
6. Aibar S, González-Blas CB, Moerman T, et al.. *SCENIC: single-cell regulatory network inference and clustering*. Nature Methods. 2017; 14:1083-1086. <https://doi.org/10.1038/nmeth.4463>
7. Blondel VD, Guillaume JL, Lambiotte R, Lefebvre E.. *Fast unfolding of communities in large networks*. Journal of Statistical Mechanics. 2008; P10008. <https://doi.org/10.1088/1742-5468/2008/10/P10008>
8. Stuart T, Butler A, Hoffman P, et al.. *Comprehensive Integration of Single-Cell Data*. Cell. 2019; 177:1888-1902.e21. <https://doi.org/10.1016/j.cell.2019.05.031>
9. Luecken MD, Theis FJ.. *Current best practices in single-cell RNA-seq analysis: a tutorial*. Molecular Systems Biology. 2019; 15:e8746. <https://doi.org/10.15252/msb.20188746>
10. Satija Lab.. *Seurat Guided Clustering Tutorial - PBMC 3k*. Seurat documentation. 2026; compiled 28 April 2026. https://satijalab.org/seurat/articles/pbmc3k_tutorial
11. 10x Genomics.. *3k PBMCs from a Healthy Donor*. 10x Genomics dataset. 2016; 2,700 cells; Universal 3'. <https://www.10xgenomics.com/cn/datasets/3-k-pbm-cs-from-a-healthy-donor-1-standard-1-1-0>

Fin du rapport